

DAG 구조에서 게이트·파셜 백프롭을 통한 오류 전파율(EPR) 측정 연구

멀티 에이전트 연구 기획안 — 지도교수님 검토 요청

Pass/Fail/Ambiguous 사전 실험 → 게이트+백프롭 Ablation 실험으로의 전환, 그리고 3대 문의점 정리

1. 연구 배경

에이전트 하네스·반복 루프 평가 연구의 한계 검토에서 출발했다.

아이데이션 & DAG 채택 이유

- 출발 주제 — 멀티 에이전트 시스템(MAS)의 성능 평가
- 문제 — 협업 시 오류·성능을 깨끗하게 측정할 방법 부재
- DAG(단방향 비순환 그래프): 노드=에이전트, 엣지=출력→입력 의존
 - 위상 정렬로 실행 순서가 결정론적
 - Fault Injection 위치·전파 경로를 명확히 분리 가능
 - 평가·측정 환경으로 적합

관련 논문

- SHIELDA** (arXiv:2508.07935, 2025) — 상류 모듈 오류가 미탐지 시 전파되어 cascading failure 유발. 검증 체크포인트 삽입을 해법으로 제시 (= '게이트'의 원형)
- AgentDebug** (arXiv:2509.25370, 2025) — 단일 root-cause 교정만으로 실패 궤적이 성공으로 전환 가능. 게이트의 가치를 뒷받침하는 가설적 토대. AgentErrorBench 데이터셋 제공

2. 실험 1 — Pass/Fail/Ambiguous(PFA) 사전 실험

게이트 판정 기준으로 PFA 3분류를 적용 → Ambiguous 미발생, 변별력 부재 확인.

판정	의미

Pass	통과
Fail	차단
Ambiguous	판정 불가 — 거의 발생하지 않음

결과 & 함의

- Ambiguous 판정이 거의 발생하지 않음 → 게이트 변별력 부재
- LLM 출력이 고르게 고품질 → Fail/Ambiguous 자체가 드물
- Ambiguous가 나와도 신뢰 어려움 (모호성 오귀인 경향)
- → 판정 축을 '품질 채점'에서 '오류 전파 여부'로 전환 필요

관련 논문 (PFA·판정 불가 평가)

- **Sparse Neurons...** (arXiv:2509.13664) — 응답을 ACCEPTABLE/UNACCEPTABLE/NEITHER 3분류
- **Autorubric** (arXiv:2603.00077) — CANNOT_ASSESS verdict, 판정 강제 시 점수 불신뢰
- **AbstentionBench** (arXiv:2506.09038) — 모호·불충분 질의에서 절제 실패의 구조적 공백

3. 실험 2 — 게이트 + 파셜 백프롭 (현재)

판정 축을 오류 전파 차단 여부로 전환, 종속변수 EPR 정립.

파이프라인 구조

[노드1: 검색] → (게이트A) → [노드2: 요약] → (게이트B) → [노드3: 보고서]

|

└ 파셜 백프롭: reject 시 상류 노드(노드1) 재실행 (구조 사이클 아님)

핵심 개념

- 게이트(**Gate**) — 노드 출력이 하류로 흐르기 전 통과/차단을 판정하는 검문소. 품질 채점이 아니라 전파 차단 여부만 판정
- 파셜 백프롭(**Partial Backprop**) — 오류를 상류로 역추적해 표적 재실행하는 보정 신호. gradient 아님(DenoiseFlow). 역엡지 없어 DAG 보존(GraphTracer)
- 핵심 선행연구 — Node Evaluation(베이징대, arXiv:2510.19420): DAG+백프롭으로 악성 에이전트 이진 탐지·차단(보안). → EPR 연속 정량화로 차별화

“DAG가 깨지는 것 아닌가?”에 대한 답

파셜 백프롭은 그래프에 역방향 엣지를 추가하지 않는다. 구조 그래프(static DAG)의 위상은 보존되고, 백프롭은 그 위에서 root cause 노드를 다시 실행하는 조건부 루프일 뿐이다. 재실행을 ‘되돌아감’이 아니라 ‘시간축 뒤에 새 노드 추가($B \rightarrow B'$)’로 보면 시간 방향으로 여전히 단방향이며 사이클이 없다. (RNN도 시간축으로 펼치면 DAG가 되는 것과 같은 원리.)

핵심 선행연구 상세 — Node Evaluation

- 저자: Chengcan Wu, Zhixin Zhang, Mingqian Xu, Zeming Wei, Meng Sun (베이징대학교)
- arXiv:2510.19420 (2025.10.22), 분야 cs.CR(보안), 미peer-review 프리프린트
- 내용: MAS를 DAG로 재구성 → contribution score + 백프롭으로 악성 에이전트 탐지 → 엣지 삭제로 복구 (이진 게이트)
- 한계 → 착안점: 악의 여부 이진 차단에 머뭇(전파 정도 미측정), 목적이 보안(공격 방어)이라 우발적 오류에 직접 적용 안 됨. 본 연구는 같은 DAG+게이트 구성을 빌려 EPR을 연속 정량화하는 신뢰성 연구로 전환

4. 문의점 — 결정사항 3가지

용어 정리

- MAS** (Multi-Agent System): 다중 LLM 에이전트 협업 시스템
- DAG** (Directed Acyclic Graph): 단방향 비순환 그래프, 위상 정렬로 실행 순서 결정론적
- EPR** (Error Propagation Rate): 오류 전파율 = 오염된 하류 노드 수 / 전체 하류 노드 수
- Ablation Test**: 구성요소를 하나씩 빼서 각 기여를 분리 측정
- Fault Injection**: 오류를 특정 노드에 의도 주입해 전파 관찰

결정사항 1 — Ablation 비교 축

	설명
Option A	Baseline Agent → 게이트 O → 게이트 + Partial Backprop (2단계 ablation)
Option B	Baseline Agent → 단순 게이트 → 엄격 게이트 (임계값 강약 비교)
Option C	Baseline Agent → 게이트 → 게이트 + 적응형 재실행 (재실행 방식 비교)

→ Option A 우선 검토 중 (게이트 유무·백프롭 유무를 독립 변수로 분리해 기여점 확립)

결정사항 2 — 오류전파율 측정 지표

	설명
방식 A	EPR = 오류 흡수 노드 수 / 전체 하위 노드 수
방식 B	S1→S2→S3 단계별 조건부 전파율 (AgentProp-Bench 방식)
방식 C	루트코즈 실패 vs 전파 실패 분리 (AgentEval 2026 방식)

→ 방식 C 우선, 방식 A+B 병행도 검토 중

결정사항 3 — 노드 평가 범위

- 정형만 (수치 위반): 구현 단순, 일반화 주장 약함
- 혼합 분리 집계 (정형 + 비정형): 전파 패턴 차이를 추가 기여점으로 확보 가능

요청 1 — 협업·실행 방식 피드백

세 문의점이 정리되면 팀원이 다같이 모여 각자 실험 코드를 작성·실행할 계획. 이 방식이 적절한지 피드백 요청.

요청 2 — 필수 학습 논문

반드시 학습해야 할 논문이 있는지. 가장 가까운 선행연구로 Node Evaluation(2510.19420)을 이미 식별 — 차별점은 EPR·단방향 통제. 논문 학습·작성 경험이 많지 않아 여러 논문을 산발적으로 학습 중인 상황도 함께 공유.

5. 참고 문헌 요약

설계 정당화 · 차별점 부각 · 가설/데이터 — 역할별 분류

논문	arXiv	T 연구에서의 역할
Node Evaluation	2510.19420 (베이징대, cs.CR)	DAG+백프롭 악성 탐지 — 차별점 기준선
DenoiseFlow	2603.00532	파설 백프롭의 형식적 선례 (기호적 backprop)

GraphTracer	2510.10581	DAG 단방향성 방어 + 루트코즈/전파 분리 (결정2)
AgentDebug	2509.25370	핵심 가설 + AgentErrorBench 데이터셋 (결정3)
SHIELDA	2508.07935	게이트(검증 체크포인트) 개념 정당화
From Spark to Fire	2603.04474	Fault Injection + ablation 구조 템플릿 (결정1)
Removal-Based Attribution	2605.27621	기여도 분리 방법론(LOO·Shapley) 근거/ 한계

※ 2026년 발행분(2602·2603·2604·2605번대)은 발송 전 arXiv에서 번호·저자·연도 재확인 권장