

노드 기여도 역전파를 통한 멀티에이전트 시스템의 오염 공격 방어

Securing Multi-Agent Systems Against Corruptions
via Node Contribution Backpropagation

Chengcan Wu^{1*} Zhixin Zhang^{1*} Mingqian Xu¹ Zeming Wei^{1†} Meng Sun^{1†}

¹베이징대학교(Peking University) *공동 제1저자 †교신저자

제43회 국제 머신러닝 학술대회(ICML 2026) 논문집, 대한민국 서울. PMLR 306, 2026.

초록

멀티에이전트 시스템(Multi-Agent Systems, MAS)은 대규모 언어 모델(Large Language Model, LLM) 응용에서 널리 쓰이는 패러다임으로 자리잡았다. 그러나 MAS의 복잡한 다중 에이전트 설계는 고유한 신뢰성 문제를 야기한다. 적대적 에이전트가 잘못된 정보를 주입하면 그 정보가 시스템 전체로 전염성 있게 전파되어 정상 에이전트를 오염시키고 잘못된 출력을 초래할 수 있다. 기존의 그래프 기반 방어법은 에이전트를 노드로, 통신을 엣지로 모델링하지만 정적 그래프 방어에 국한된다. 본 논문에서는 MAS 통신을 부호 있는 유향 비순환 그래프(signed directed acyclic graph)로 모델링하고, 역방향 전파(backward propagation)를 통해 최종 결정에 대한 각 에이전트의 기여도를 계산하는 동적 방어 패러다임을 제안한다. 이를 통해 악성 에이전트를 정확히 식별·격리하여 다중 에이전트 협업 과제를 안전하게 보호할 수 있다. 복잡하고 동적인 MAS 환경에서의 실험 결과, 본 방법이 기존 MAS 방어 기법을 크게 능가하여 신뢰할 수 있는 MAS 배포를 위한 효과적인 가드레일을 제공할 수 있음을 보인다. 코드는 <https://github.com/ChengcanWu/BPD>에서 이용 가능하다.

1. 서론

대규모 언어 모델(LLM)은 외부 도구와 결합하여 자율 에이전트를 형성해 왔다(Wang et al., 2024a). LLM의 기능을 강화하기 위한 연구는 단일 에이전트 구조에서 멀티에이전트 시스템(MAS)으로 옮겨가고 있으며(Yan et al., 2025), 소프트웨어 공학(He et al., 2025a), 시장 분석(Chudziak & Wawer, 2024), 웹 작업 실행(Zhang et al., 2025) 등 다양한 분야에서 큰 진전을 이루고 있다.

그러나 MAS는 구조적 복잡성이 증가하면서 에이전트가 더 복잡하고 빈번한 정보 교환에 노출되어, 시스템이 공격에 더 취약해진다. 개별 LLM을 겨냥한 공격과 달리, MAS에 대한 공격은 전염성(contagious) 특성을 보인다(Wang et al., 2025a; He et al., 2025b). 즉, 하나의 LLM 출력을 조작하여 해로운 내용을 주입하면 그 악성 영향이 인접 LLM으로 전파되어 시스템 전반에 연쇄적 실패(cascading failure)를 일으킨다(Tianjie et al.; Zheng et al., 2025). 또 다른 전략들은 과거 상호작용 기록을 분석하여 특정 에이전트를 겨냥한 적대적 프롬프트를 만들어 유사한 효과를 낸다(Lee et al., 2025). 본 논문에서는 이러한 전염성·전파 기반 공격을 MAS에 대한 오염 공격(corruption attack)이라 부른다.

이러한 공격을 방어하기 위해 여러 전략이 제안되었다. BlockAgents(Chen et al., 2024a)와 같은 출력 기반

방어는 다회차 토론(multi-round debate)을 활용하고, AgentForest(Li et al., 2024)는 출력 유사도를 비교하여 오염된 에이전트를 식별한다. 그러나 이러한 방법들은 미묘한 텍스트 변형에 여전히 취약하며(Lin et al., 2024; Böke et al., 2025; Xu et al., 2026), 공격자가 평가자를 직접 겨냥하면 우회될 수 있다(Chen et al., 2024a). 이를 보완하는 또 다른 연구 흐름은 MAS를 그래프 관점에서 모델링하여 에이전트를 노드로, 상호작용을 유향 엣지로 취급한다(Liu et al., 2026; Bei et al., 2025). 이 틀 안에서 Huang et al.(2025)은 강건한 구성을 찾기 위해 토폴로지를 경험적으로 비교하지만, 이러한 정적 설계는 진화하는 공격이나 동적 환경에 적응할 수 없다(Yan et al., 2026; Liu et al., 2026). G-Safeguard(Wang et al., 2025b)는 각 에이전트의 내부 상태와 국소 통신에 대해 분류기를 학습시켜 동적 방어로 나아가지만, 국소 신호에만 의존하여 오염된 정보가 최종 결정으로 어떻게 전파되는지를 포착하지 못해 신뢰할 수 있는 탐지에 필요한 전역적 검증이 부족하다.

이러한 한계를 해결하기 위해, 우리는 MAS 상호작용 그래프 전체에 걸쳐 에이전트 영향력을 전역적으로 추론하는 동적 방어 기법인 **역전파 탐지(Backward Propagation Detection, BPD)**를 제안한다. 그림 1에 개략적으로 나타냈듯이, 우리는 먼저 MAS 통신을 부호 있는 유향 비순환 그래프(signed DAG)로 재구성한다. 여기서 시간 노드(temporal node)는 각 통신 라운드의 에이전트를 나타내며, 각 엣지는 수신자가 송신자에 대해 반대·무시·동의 중 어느 것에 해당하는지를 나타내는 기여도 점수를 담는다. 이 부호 있는 DAG가 주어지면, 우리는 최종 답변으로부터 역전파를 통해 최종 결정에 대한 각 에이전트의 기여도를 계산한다. 이는 PageRank 방식의 재귀 메커니즘(Brin et al., 1998; Page et al., 1999)으로, DAG의 연쇄 법칙(chain-rule) 구조를 활용하여 국소적 합의와 그 하류 영향(downstream impact)을 단일 효율적 패스로 집계한다. 이 모델링 하에서, 기여도 점수가 다수로부터 크게 벗어나는 에이전트를 잠재적 악성 노드로 표시하고, 그들이 발신한 통신을 제거하여 그래프를 복구한다. 탐지와 복구가 고정된 학습 분류기가 아니라 질의(query)별로 수행되므로, BPD는 질의 후 비정상 행동을 보이는 에이전트를 즉시 탐지할 수 있어 진화하는 공격과 동적 MAS 토폴로지에 적응적이다.

우리는 두 가지 MAS 구조(Flat (Li et al., 2023a)와 Hierarchical (Chen et al., 2024b)), 여러 LLM 백본, 그리고 지식 질의응답과 개방형 생성을 아우르는 벤치마크에 걸쳐, 다섯 가지 대표적인 MAS 오염 공격 하에서 BPD를 평가한다. 이를 통해 BPD는 평균

90% 이상의 정확도로 악성 에이전트를 식별하여 가장 강력한 베이스라인을 능가하며, 벤치마크 전반에서 과제 정확도를 3%에서 7%까지 향상시킨다. 나아가 기존 방법이 탐지하기 어려워하는 의미 변형(semantic-modification) 공격에서는 그 격차가 약 10%까지 벌어진다. 더 중요하게, 그래프 구조와 공격자 정체가 시간에 따라 변하는 동적 MAS 시나리오에서 경쟁 방어법들은 평균 3% 성능이 저하되는 반면, BPD는 정적 그래프 성능을 그대로 유지하여 적응적 분석의 이점을 확인시켜 준다. 마지막으로, 본 방어 기법은 멀티에이전트 시스템의 보안을 보장하면서 10% 미만의 추가 시간 오버헤드만을 발생시켜 강력한 실용적 가치를 보인다.

요약하면, 본 연구의 기여는 다음과 같다.

1. 국소 신호에만 의존하는 기존 방어의 핵심 한계를 해결하여, 에이전트 영향력에 대한 원리적·전역적 분석을 가능케 하는 MAS 통신의 부호 있는 DAG 정식화를 제안한다.
2. MAS 내 서로 다른 에이전트의 기여도를 신뢰성 있게 평가하여 잠재적 악성 에이전트를 탐지하고 시스템 무결성을 복원하는 새로운 역전파 기법을 제안한다.
3. 다양한 MAS 구조, 공격 유형, 백본 모델에 걸친 종합적 실험을 통해 BPD가 우수한 방어 성능을 달성하며, 특히 정적 방어가 크게 저하되는 동적 시나리오에서 두드러진 이점을 보임을 입증한다.

2. 관련 연구

MAS에 대한 오염 공격. 멀티에이전트 시스템의 부상과 함께 보안 문제가 점점 더 주목받고 있다. 기존 공격은 대체로 세 가지 범주로 나뉜다. 에이전트 침해(agent compromise), 안전성 조작(safety manipulation), 교란 기반 전략(perturbation-based strategies)이다. 에이전트 침해는 해로운 프롬프트를 주입하고 에이전트를 미세조정하여, 논리적으로는 정교하지만 틀린 설명을 생성하게 함으로써 협력자를 오도하고 집단 추론을 탈선시킨다(Amayuelas et al., 2024). 안전성 조작은 안전 방어 장치를 악용하여 무해한 질의를 위험한 것으로 거짓 표시함으로써 과도한 거부 응답을 유발한다(He et al., 2025b). 교란 기반 전략은 에이전트를 차선의 선택으로 유도하거나 토론 목표를 미묘하게 바꾸어 은밀한 영향을 추구하거나(Xie et al., 2025), 콘텐츠 필터를 회피하는 감지 불가능한 텍스트 교란을 적용한다(Lin et al., 2024). 종합적으로 이러한 공격들은 에이전트 상호작용을 통해 악성 영향을 전파하여 연쇄적 오류와 시스템 전반의 오염을 유발한다.

MAS를 위한 방어. 이에 대응하여, 기존 방어법은 출력 모니터링, 그래프 기반 탐지, 협업적 검증을 채택한다. 출력 중심 방법은 심리측정 점수(psychometric score)를 추적하여 해로운 콘텐츠를 표시하지만(Xie et al., 2025), 보정에 많은 노력이 들고 공격자가 메시지의 감성적·설득적 어조를 조작하면 회피될 수 있다. 그래프 기반 접근은 MAS를 그래프 신경망(GNN)으로 모델링하고 에이전트 출력에 대해 분류기를 학습시키지만(Wang et al., 2025b), 국소 신호에 의존하여 오염 정보가 최종 결정으로 어떻게

전파되는지에 대한 전역적 관점이 부족하고, 경량 텍스트 변형 같은 은밀한 교란을 탐지하기 어렵다. 협업적 방어는 동료 검증이나 전담 검사관(inspector) 에이전트로 회복력을 높이지만(Huang et al., 2025), 공격자가 검토자를 속이면 무력화된다. 더욱이 대부분의 기존 방어는 정적 통신 그래프를 가정하여 동적으로 진화하는 공격이나 에이전트 상호작용에 적응할 수 없다. 또한 출력 중심 방법과 그래프 기반 방법 모두 토폴로지가 변하면 재학습이 필요하여 전역성 오염에 저항하기 어렵다.

3. 방법론

MAS에서 악성 에이전트를 식별하기 위해, 우리는 먼저 이후의 계산 편의를 위해 3.1절에서 MAS를 그래프로 모델링하여 에이전트 간 통신 토폴로지를 포착한다. 다음으로 3.2절에서 부호 있는 네트워크를 구성하여 에이전트 간 통신을 점수화함으로써 각 에이전트의 영향력을 평가한다. 마지막으로 3.3절에서 역전파를 수행하여 노드 기여도를 정량화하고, 비정상적 기여도 점수를 보이는 노드를 식별하여, 탐지된 악성 에이전트가 발신한 정보를 제거함으로써 MAS를 복구한다. 3.4절에서 전체 파이프라인을 요약하고 논의한다.

3.1. MAS 그래프

시간 DAG 구성. 먼저 MAS를 그래프로 모델링하는 방법을 소개한다. n 개의 에이전트로 구성된 멀티에이전트 시스템, 즉 $A = \{A^{(1)}, \dots, A^{(n)}\}$ 을 고려하자. MAS 구조의 복잡성으로 인해 통신 그래프는 매우 다양할 수 있다. 그러나 적절한 처리를 통해 이를 유향 비순환 그래프(DAG)로 변환할 수 있다(Digitale et al., 2022). 이를 위해 우리는 토론을 타임스탬프로 분할한다. 구체적으로, MAS가 T 라운드의 대화를 거친다고 가정하고, 라운드 t 에서의 $A^{(i)}$ 를 나타내는 시간 노드 $A_t^{(i)}$ 를 도입한다. 여기서 $t = 1, \dots, T$ 이고 $i = 1, \dots, n$ 이다. 엣지 $e_t(i, j)$ 는 라운드 t 에 $A^{(i)}$ 에서 $A^{(j)}$ 로 메시지가 전송됨, 즉 $A_t^{(i)}$ 에서 $A_{t+1}^{(j)}$ 로의 전송을 나타낸다(그림 1 참조). 각 유향 엣지가 연속된 시간 스텝을 연결하므로 순환이 형성될 수 없어, 재구성된 그래프가 DAG임이 보장된다.

그래프 표기. 편의를 위해 그래프를 $G = (V, E)$ 로 쓰며, 여기서

$$V = \{A_t^{(i)} \mid t = 1, \dots, T; i = 1, \dots, n\} \\ = \{C_1, \dots, C_N\}, \quad N = nT, \quad (1)$$

$E = \{e_{ij} \mid i, j = 1, \dots, N\}$ 이고, $N_{t,i}^+ = \{A_{t+1}^{(j)} \mid e_{t,i \rightarrow j} \in E\}$ 이며 출력 차수(out-degree)는 $k_{t,i} = |N_{t,i}^+|$ 이다.

3.2. 부호 있는 엣지 점수화로 연결 추출

MAS 그래프를 기반으로, 우리는 부호 있는 네트워크를 사용하여 통신을 분석한다. 양의 부호를 가진 엣지 e_{ij} 는 C_j 가 C_i 에 대해 가지는 동의 또는 신뢰를 나타내고, 음의 부호는 불신 또는 반대를 나타낸다.

구체적으로, 엣지 e_{ij} 에서 수신자 C_j 는 송신자 C_i 로부터 메시지 s_i 를 받아 s_j 를 출력한다. 우리는 $g_{ij} = f(s_i, s_j) \in \{-1, 0, 1\}$ 을 계산하며, f 는 MAS와




Figure 1. 본 기법 BPD의 개요. 단계 1에서 MAS를 유향 비순환 그래프(DAG)로 재구성한다. 단계 2와 3에서 각 엣지의 기여도 점수와 최종 결정으로부터의 역전파를 이용해 각 에이전트의 최종 결정에 대한 기여도를 추출한다. 이는 잠재적 악성 에이전트를 판별하는 데 도움이 된다. 이후 단계 4에서 탐지된 악성 에이전트가 발신한 정보를 제거하여 MAS를 복구한다. 점선은 해당 통신 엣지가 삭제되었음을 나타낸다. (그림 내 라벨은 원본 영문이며, 한글 대응은 다음과 같다: Graph Reconstruction=그래프 재구성, Graph Operation=그래프 연산, Score Backward=점수 역전파, Graph Repair=그래프 복구, Malicious Agent=악성 에이전트, Infected Agent=감염된 에이전트, Deleted Answer/Suggestion=삭제된 답변/제안.)

독립된 LLM으로 구현된다(프롬프트는 부록 A.3 참조). 점수 $-1/0/1$ 은 각각 모순, 낮은 기여, 양의 기여를 나타낸다. C_i 가 악성이고 C_j 공격에 성공하면 $g_{ij} = 1$ 이고, 탐지되면 $g_{ij} = -1$ 이다. 신뢰성은 부록 B.4에서 검증한다.

3.3. 노드 기여도 결정

부호 있는 영향 연산자. $G \in \mathbb{R}^{N \times N}$ 을 부호 있는 엣지 가중치 행렬이라 하고, $e_{ij} \in E$ 이면 $G_{ij} = g_{ij}$, 그렇지 않으면 $G_{ij} = 0$ 이다. 출력 차수 대각 행렬을 $D = \text{diag}(k_1, \dots, k_N)$ 으로 정의하며, $k_i = |N^+(C_i)|$ 이다. 행 정규화된 부호 있는 전파 연산자는 다음과 같다.

$$B = D^{-1}G, \quad (2)$$

여기서 D^{-1} 은 $k_i > 0$ 일 때만 $1/k_i$ 를 사용하고 그렇지 않으면 0이다. 성분 B_{ij} 는 엣지 e_{ij} 를 통한 C_j 의 C_i 에 대한 부호 있는 영향력을 C_i 의 출력 차수로 정규화하여 정량화한다.

역방향 점수 전파. $S(C_i)$ 를 노드 C_i 의 기여도 점수라 하자. BPD는 라운드 T 에서 1로 시간을 거슬러 점수를 전파하며, 각 노드의 후속 노드로부터 부호 있는 영향을 집계한다.

$$S(C_i) = \begin{cases} \frac{1}{k_i} \sum_{C_j \in N^+(C_i)} g_{ij} S(C_j) = \sum_{j=1}^N B_{ij} S(C_j), & k_i > 0 \\ 0, & k_i = 0 \end{cases} \quad (3)$$

벡터 형태로, $S^{(t)} = [S(A_t^{(1)}), \dots, S(A_t^{(n)})]^\top$ 일 때

$$S^{(t)} = P^{(t)} S^{(t+1)}, \quad t = T-1, \dots, 1, \quad (4)$$

이며, $P^{(t)} \in \mathbb{R}^{n \times n}$ 은 다음과 같은 레이어별 연산자이다.

$$P_{ij}^{(t)} = \begin{cases} g_{t,i \rightarrow j} / k_{t,i}, & j \in N_{t,i}^+, \\ 0, & \text{그 외.} \end{cases} \quad (5)$$

종단 레이어 초기화는 경계 조건의 역할을 한다.

$$S(A_T^{(i)}) = \begin{cases} +1, & y_i = y_{\text{final}}, \\ -1, & \text{그 외,} \end{cases} \quad (6)$$

여기서 y_i 와 y_{final} 은 각각 $A^{(i)}$ 와 MAS의 답변이다. G 가 DAG이므로 식 (4)는 반복 수렴 없이 단일 역방향 패스로 얻어지는 유일해를 가진다. 즉,

$$S^{(t)} = P^{(t)} P^{(t+1)} \dots P^{(T-1)} S^{(T)}. \quad (7)$$

따라서 BPD는 각 에이전트의 최종 결정을 향한 부호 있는 누적 영향력을 추적한다(그림 1).

PageRank와의 연결. 고전적 PageRank(Brin et al., 1998; Page et al., 1999)는 다음과 같이 반복적으로 갱신한다.

$$r^{(\ell+1)} = (1-d) \frac{1}{N} + d W^\top r^{(\ell)}, \quad (8)$$

여기서 $d \in (0, 1)$ 은 감쇠 계수(damping factor)이고, $0 \rightarrow i$ 가 존재하면 $W_{ji} = 1/k_j$, 그렇지 않으면 0이다. BPD는 DAG 상의 부호 있는 레이어별 PageRank로 볼 수 있다. $P^{(t)}$ 는 $g_{t,i \rightarrow j} \in \{-1, 0, 1\}$ 로 $W^\top$ 를 일반화하고, 감쇠/순간이동(teleportation)을 경계 초기화(식 6)로 대체하며, 거듭제곱 반복(power iteration)을 단일 위상정렬 역방향 패스(식 7)로 대체한다.

에이전트 수준 집계 및 이상치 탐지. $T(i) = \{t \mid A_t^{(i)} \text{가 출력을 생성}\}$ 이라 하자. 에이전트 수준 기여도와 쌍별 편차는 다음과 같다.

$$\hat{S}(A^{(i)}) = \frac{1}{|T(i)|} \sum_{t \in T(i)} S(A_t^{(i)}),$$

$$\Delta(i) = \frac{1}{n-1} \sum_{j \neq i} \left| \hat{S}(A^{(i)}) - \hat{S}(A^{(j)}) \right|. \quad (9)$$

탐지된 악성 에이전트 집합은

$$M = \{A^{(i)} \in A \mid \Delta(i) \geq \epsilon\}, \quad (10)$$

이며, $\epsilon > 0$ 은 임계값이다. 직관적으로, 공격이 실패하면 음의 엣지 부호로 인해 공격자의 S 가 낮아지고, 성공하면 전염으로 인해 그 점수가 부풀려진다. 두 경우 모두 큰 $\Delta(i)$ 를 만든다.

통신 가지치기를 통한 완화. M 이 주어지면 $E_M = \{e_{t,i \rightarrow j} \in E \mid A^{(i)} \in M\}$ 이라 하자. 우리는 다음과 같이 그래프를 복구한다.

$$G' = (V, E \setminus E_M). \quad (11)$$

이는 오염된 정보의 추가 전파를 차단한다. 경험적으로 BPD는 93%의 탐지 성공률을 달성하며, 나머지 경우에도 가장 영향받은 에이전트를 가지치기하면 보안이 개선된다.

3.4. 요약 및 논의

BPD의 전체 절차는 알고리즘 1에 요약되어 있다. 우리는 또한 경량적·적응적 방어 기법으로서 BPD의 핵심 특징을 다음과 같이 강조한다.

- **학습 불필요.** BPD는 부호 있는 역전파를 통해 질의별로 탐지와 복구를 수행한다. 이는 오프라인 학습의 필요성을 없애고 다양한 MAS 토폴로지에 효율적으로 적응할 수 있게 한다.
- **효율성.** 역전파는 DAG에 대한 단일 위상정렬 패스(식 7)만을 필요로 하여, 반복 수렴이나 매 스텝의 값비싼 LLM 기반 점수화를 피한다.
- **해석 가능성.** 부호 있는 전파 연산자(식 2)는 영향력 추적을 위한 투명한 메커니즘을 제공한다. 각 노드의 기여도 점수는 최종 결정에 대한 부호 있는 누적 영향을 직접 반영한다.

4. 실험

본 절에서는 BPD의 효과성, 적응성, 효율성을 검증하기 위해 여러 관점에서 평가한다.

4.1. 실험 설정

MAS 과제 및 데이터셋. 지식 질의응답에는 수학, 화학, 컴퓨터과학, 보안 등의 하위 도메인을 포함하는 MMLU 데이터셋(Son et al., 2025)을 사용했으며, 각 도메인은 100개의 테스트 샘플을 포함한다. 개방형 생성에는 세 데이터셋을 사용했다. 상식 질문에는 Alpaca(Taori et al., 2023), 요약 과제에는 Samsun(Gliwa et al., 2019), 의료 질문에는 ChatDoctor(Li et al., 2023b)이다.

알고리즘 1 역전파 탐지(BPD)

입력: $G = (V, E)$: 시간 노드 $C_1, \dots, C_N$ 을 갖는 MAS의 DAG; $g_{ij} \in \{-1, 0, 1\}$: 엣지 e_{ij} 상의 부호 있는 기여도 점수; ϵ : 이상치 탐지 임계값.
출력: 탐지된 악성 에이전트 집합 M .

- 1: **단계 1: 초기화.** 에이전트 i 가 최종 결정과 일치하면 $S(A_T^{(i)}) = +1$, 아니면 -1 로 설정.
- 2: **단계 2: 역전파.** $t = T - 1$ 부터 1까지, $S(C_i) = \frac{1}{k_i} \sum_{j: e_{ij} \in E} g_{ij} \cdot S(C_j)$ 계산.
- 3: **단계 3: 집계.** 에이전트별 평균 $\hat{S}(A^{(i)})$ 를 모든 라운드에 걸쳐 계산.
- 4: **단계 4: 이상치 탐지.**

$$M \leftarrow \left\{ A^{(i)} \mid \frac{1}{n-1} \sum_{j \neq i} |\hat{S}(A^{(i)}) - \hat{S}(A^{(j)})| \geq \epsilon \right\}.$$
- 5: **단계 5: 완화.** M 에 속한 에이전트의 모든 발신 메시지를 제거.
- 6: **반환** M

평가 설정. 우리는 이차원 평가를 채택했다. (i) 모델 출력과 참조 답변 간 유사도를 측정하는 Bleurt(Sellam et al., 2020), (ii) 응답을 1점에서 5점으로 채점하는 GPT-4(Achiam et al., 2023)이다.

기본 LLM. 최신 모델을 평가하기 위해 DeepSeek-V3(Liu et al., 2024)와 GPT-4o(Hurst et al., 2024)를 테스트했다.

MAS 설계. 고정 그래프 구조로 두 가지 구성을 사용했다. 모든 에이전트가 동등하게 협업하는 Flat(Li et al., 2023a; Wang et al., 2024b), 그리고 에이전트가 답변자와 검토자 같은 서로 다른 역할을 맡는 Hierarchy(Chen et al., 2024b; Liang et al., 2024)이다. 상세한 MAS 구성은 부록 A.1에 있다.

오염 공격. 우리는 (Amayuelas et al., 2024)의 공격 방법을 기본 설정으로 채택했다.

베이스라인. G-Safeguard(Wang et al., 2025b), AGENTXPOSED(Xie et al., 2025), Challenger, Inspector(Huang et al., 2025)와 비교했다. 상세한 베이스라인 설정은 부록 A.2에 있다.

하이퍼파라미터. 임계값 ϵ 은 4.5절의 연구에 기반하여 경험적으로 1.5로 설정했다.

4.2. 고정 그래프 구조에서의 결과

본 실험에서는 GPT-4o를 사용하여 MMLU 데이터셋에서 Flat과 Hierarchy 구조의 MAS를 평가했다. Flat 구조에서는 5개의 에이전트가 협력적으로 토론하여 최종 답변에 도달한다. Hierarchy 구조에서는 5개의 응답자 에이전트가 초기 답변을 제공하고, 2개의 평가자가 피드백을 제공하며, 응답자가 이에 따라 답변을 수정한다. 기본 공격은 그럴듯한 설명과 함께 에이전트가 틀린 답을 선택하도록 조작한다.

표 1과 표 2의 결과는 BPD가 두 구조에서 각각 정확도를 10%p와 8%p 향상시킴을 보인다. 공격 하에서 BPD는 최대 정확도 하락 3%, 평균 하락 2% 미만으로 강건한 방어를 유지한다. 표 1은 BPD의 표준편차가 두 구조 모두 0.6%에 불과하여 높은 안정성을 나타내며, 평균 정확도(85.4%와 87.5%)가 최고 베이스라인(83.7%와 85.5%)을 크게 능가함을 보인다. 표 2는 BPD가 모델 학습이 전혀 필요 없음에도 탐지 정확도에서 G-Safeguard를 각각 2%, 6% 능가함을

보인다. DeepSeek-V3 결과는 부록 B.1에 있다.

텍스트 기반 응답 데이터셋(표 3)에서, 공격은 BRT 점수를 15.7%–15.8%, GPT 점수를 8.8%–11.9% 저하시킨다. BPD를 적용하면 하락폭이 BRT 1.3%–1.5%, GPT 0.6%–0.8%로 줄어든다. 표 4는 BPD가 평균 95%의 탐지 성공률을 달성함을 보인다. DeepSeek-V3 결과는 부록 B.2에 있다.

4.3. 오염 공격에 대한 강건성

BPD의 방어 능력을 검증하기 위해, 우리는 여러 공격 기법을 평가했다. Harmful(Amayuelas et al., 2024), Suboptimal, Reframing(Xie et al., 2025), Trigger(He et al., 2025b), Modification(Lin et al., 2024)이다. 각 설명은 다음과 같다.

- **None:** 공격이 구현되지 않음.
- **Harmful:** 공격자가 틀린 답을 논리적으로 설명하는 해로운 프롬프트를 입력하여 MAS를 교란하고 다른 에이전트를 잘못된 출력으로 유도.
- **Suboptimal:** 공격자가 정답을 피하면서 차선의 답을 선택하여 공격을 더 은밀하게 만들.
- **Reframing:** 공격자가 질문을 재구성하여 고의로 오해석함으로써 다른 에이전트의 응답을 교란.
- **Trigger:** 공격자가 질문이 위험하다고 주장하여 에이전트의 안전 방어를 과도하게 발동시켜 정상 질의 응답을 방해.
- **Modification:** 공격자가 미묘한 의미 변경으로 다른 에이전트의 출력을 모방하여 텍스트 유사도 기반 탐지를 회피.

표 5에 나타나듯, BPD는 두 MAS 구조에서 각각 7%p와 6%p의 정확도 향상을 달성하여 모든 베이스라인을 능가하며, 최고 베이스라인의 향상폭은 4%p에 그친다. 대부분의 기존 방어는 미묘한 의미 변경이 도입되는 Modification 공격에 특히 취약하다. 이 까다로운 공격에 대해 BPD는 16%p와 10%p의 향상을 확보하는 반면, 다른 방법들은 약 5%p에 그치고, 최고 성능 베이스라인인 G-Safeguard도 7%p에 머문다. 표 6은 BPD가 모든 시나리오에서 90% 이상의 탐지 정확도를 유지함을 보인다. 대조적으로 G-Safeguard는 Modification 공격에서 83%와 81%로 떨어져, 기존 방법이 미묘한 의미 변형 공격을 탐지하기 어려움을 확인시켜 준다. 외부 탐지가 아닌 에이전트 점수화에 의존하는 BPD의 자가 모니터링 메커니즘은, 특히 공격이 무해한 출력을 가깝게 모방할 때 훨씬 더 효과적임이 입증된다.

4.4. 동적 그래프 실험

동적 그래프 방어에서 BPD의 효과성을 검증하기 위해, 우리는 동적 멀티에이전트 시스템을 구성했다. 이는 MAS가 다양한 측면에 적용되어 그래프 구조를 빈번히 변경해야 하는 실제 시나리오를 모사하는 것을 목표로 한다. 또한 공격자가 점점 다양한 전략을 구사함에 따라, 방어 기법이 장기간에 걸쳐 보호를 지속할 수 있는지 테스트하는 것이 중요하다.

본 실험에서는 서로 다른 공격 전략을 구현하고 테스트 기간 동안 MAS의 그래프 구조를 점진적으로 변경하며,

어떤 에이전트가 공격받는지도 다양화한다. 우리의 목표는 이러한 고도로 동적인 환경에서 여러 방어 기법의 성능을 평가하는 것이다.

결과는 표 7과 표 8에 나타난다. 응답 정확도와 관련하여, 동적 시나리오에서 공격자가 공격을 개시한 후 정확도가 78%로 떨어지며, 이는 정적 그래프 공격 하의 81%, 80%와 대비된다. 이는 동적 그래프에서 공격의 변동성 증가가 더 나쁜 모델 성능으로 이어짐을 나타낸다. BPD는 88%와 85%의 정확도를 유지하여 정적 그래프 방어 대비 거의 하락을 보이지 않는다. 대조적으로 다른 방어 기법들은 정적 그래프 결과 대비 평균 3%p 감소하는 상당한 성능 하락을 보인다.

4.5. 절제 연구(Ablation Study)

역전파의 필요성을 검증하기 위해, 우리는 BPD를 역전파 없이 원시 점수(raw score)만으로 공격받은 에이전트를 모니터링하는 절제 버전과 비교했다. 절제 버전은 역전파를 전혀 수행하지 않고 평균 점수가 가장 낮은 에이전트를 예측 공격자로 식별한다. 이 절제 실험은 GPT-4o를 사용하여 MMLU 데이터셋에서 수행되었다.

표 9와 표 10의 결과는 역전파 없이는 응답 정확도가 2%–3%p 떨어지고 모니터링 정확도가 6%–8%p 감소함을 보인다. 이는 불신(distrust)이 국소 정보로서, MAS 전반에 걸친 전역적 기여가 아니라 에이전트의 직접 이웃만을 반영하기 때문이다. 따라서 원시 점수는 단독으로 기능할 수 없으며, 전역 정보를 활용하기 위해 반드시 역전파와 결합되어야 한다.

우리는 또한 서로 다른 임계값 ϵ 의 사용을 탐구했으며, 답변 정확도와 모니터 정확도 결과는 그림 2와 그림 3에 나타난다.




Figure 2. GPT-4o에서 서로 다른 ϵ 에 따른 답변 정확도(ACC). (a) Flat, (b) Hierarchy.




Figure 3. GPT-4o에서 서로 다른 ϵ 에 따른 모니터 정확도(ACC). (a) Flat, (b) Hierarchy.

ϵ 이 1.3에서 1.5로 증가함에 따라 평균 정확도가 84%에서 87%로 향상된다. 그러나 ϵ 을 1.7로 더 증가시키면 정확도가 82%로 떨어져, $\epsilon = 1.5$ 가 최적임을 확립한다. 이는 탐지 행동으로 설명된다. 작은 $\epsilon = 1.3$ 은

Table 1. MMLU 데이터셋을 사용한 GPT-4o 모델에서 여러 기법의 답변 정확도(ACC). 3회 실험을 수행하고 각 실험에서 1 표준편차를 제시한다.

구조	기법	대수	수학	화학	컴퓨터	보안	평균
	단일 LLM	89.7%±0.6%	88.7%±0.6%	70.7%±1.5%	86.7%±1.2%	80.7%±1.2%	83.3%±0.6%
Flat	무공격	95.0%±1.0%	94.7%±1.2%	75.3%±0.6%	92.0%±1.0%	85.0%±1.0%	88.4%±0.6%
	공격	78.7%±0.6%	74.7%±0.6%	64.7%±0.6%	82.3%±1.5%	81.0%±1.0%	76.3%±0.6%
	G-Safeguard	88.3%±0.6%	88.7%±0.6%	71.0%±2.0%	87.7%±1.5%	83.0%±2.0%	83.7%±1.0%
	AGENTXPOSED	90.0%±1.0%	79.0%±1.0%	67.0%±1.0%	89.0%±1.7%	87.3%±1.5%	82.5%±1.2%
	Challenger	88.7%±0.6%	87.3%±1.2%	68.3%±0.6%	84.0%±1.7%	75.3%±2.5%	80.7%±0.6%
	Inspector	84.0%±1.0%	89.0%±1.0%	65.7%±0.6%	80.7%±1.5%	75.7%±2.1%	79.0%±1.2%
	BPD (제안)	92.3%±0.6%	93.0%±1.7%	73.3%±1.5%	87.3%±2.3%	81.0%±2.0%	85.4%±0.6%
Hierarchy	무공격	95.7%±1.5%	95.3%±1.5%	75.3%±2.5%	95.0%±1.0%	82.3%±0.6%	88.7%±1.0%
	공격	81.7%±0.6%	81.7%±2.5%	66.7%±1.5%	84.7%±0.6%	78.0%±1.7%	78.6%±0.6%
	G-Safeguard	92.0%±1.0%	91.7%±2.1%	71.3%±1.5%	90.3%±2.3%	82.3%±1.2%	85.5%±0.6%
	AGENTXPOSED	85.3%±0.6%	83.3%±1.2%	68.7%±0.6%	90.0%±1.0%	82.7%±1.5%	82.0%±0.0%
	Challenger	86.3%±0.6%	87.3%±1.2%	67.7%±0.6%	86.3%±1.5%	78.3%±1.2%	81.2%±1.2%
	Inspector	87.0%±1.0%	89.7%±1.5%	68.3%±0.6%	88.0%±1.7%	79.0%±1.7%	82.4%±1.0%
	BPD (제안)	93.3%±1.2%	95.7%±2.5%	73.7%±1.5%	91.0%±3.0%	83.7%±1.5%	87.5%±0.6%

Table 2. MMLU 데이터셋을 사용한 GPT-4o 모델에서 여러 기법의 모니터 정확도(ACC).

구조	기법	대수	수학	화학	컴퓨터	보안	평균
Flat	G-Safeguard	92.3%±2.3%	90.7%±2.1%	85.7%±1.2%	87.0%±1.7%	86.0%±0.0%	88.3%±1.5%
	BPD (제안)	93.0%±1.0%	90.7%±1.5%	91.0%±1.0%	88.7%±1.5%	89.3%±1.2%	90.7%±0.6%
Hierarchy	G-Safeguard	92.3%±1.5%	89.7%±1.5%	86.3%±0.6%	85.0%±1.0%	85.7%±1.2%	87.7%±1.2%
	BPD (제안)	97.7%±1.5%	96.3%±1.5%	93.3%±0.6%	89.0%±1.7%	90.7%±0.6%	93.3%±0.6%

Table 3. GPT-4o 모델에서 텍스트 기반 응답 데이터셋을 사용한 여러 기법의 답변 정확도(ACC).

구조	기법	Alpaca		Samsum		ChatDoctor		평균 구조	
		BRT	GPT	BRT	GPT	BRT	GPT	BRT	GPT
	단일 LLM	39.4	97.2	39.2	96.6	40.0	98.0	39.5	97.2
Flat	무공격	39.8	99.4	39.5	97.6	40.0	99.4	39.8	98.8
	공격	32.0	86.8	31.9	87.2	33.4	86.6	32.4	86.8
	G-Safeguard	38.6	97.0	39.7	93.6	38.9	97.0	39.0	96.0
	AGENTXPOSED	37.0	95.2	36.4	95.4	36.4	97.8	36.6	96.2
	BPD	39.6	99.6	38.0	96.6	40.8	99.2	39.4	99.8
Hier.	무공격	40.0	99.4	39.6	96.8	40.2	98.6	39.9	98.2
	공격	32.0	92.6	34.2	89.0	33.3	86.8	33.2	89.2
	G-Safeguard	38.4	97.2	37.6	97.4	40.1	96.8	38.7	97.8
	AGENTXPOSED	37.9	96.2	37.8	95.0	38.9	95.0	38.2	96.8
	BPD	40.2	98.8	38.6	96.4	39.2	98.4	39.3	99.8

Table 4. GPT-4o 모델에서 텍스트 기반 응답 데이터셋을 사용한 여러 기법의 모니터 정확도(ACC).

구조	기법	Alpaca		Samsum		ChatDoctor		평균
		BRT	GPT	BRT	GPT	BRT	GPT	
	단일 LLM	92%	96%	86%	92%	89%	94%	89%
Flat	G-Safeguard	93%	98%	87%	91%	92%	97%	91%
	BPD (제안)	93%	98%	87%	91%	92%	97%	91%
Hier.	무공격	92%	96%	86%	92%	89%	94%	89%
	공격	93%	98%	87%	91%	92%	97%	91%
	G-Safeguard	93%	98%	87%	91%	92%	97%	91%
	AGENTXPOSED	93%	98%	87%	91%	92%	97%	91%
	BPD	93%	98%	87%	91%	92%	97%	91%

탐지율을 96%로 높이지만 일부 유효한 통신 링크를 제거하여 정확도를 약간 저하시킨다. 큰 $\epsilon = 1.7$ 은 탐지율을 47%로 낮춰 해로운 공격이 지속되도록 하여 과제 성능을 떨어뜨린다.

4.6. 채점기가 공격받을 때의 방어 성능

채점 메커니즘은 BPD에서 잠재적 공격을 탐지하는 데 핵심적이다. 그러나 이 또한 공격받을 위험이 있다. 적응형 공격이 우리의 채점 메커니즘을 감염시키는 상황을 연구하기 위해, 우리는 채점 과정을 특정하여 겨냥한 공격을 수행했다. 예를 들어, 두 텍스트 구간 사이의 원래 기여도 값이 -1 이었다면, 침해된 통신 노드는 탐지된 반대를 거짓으로 보고하기 위해 점수를 고의로 1로 바꾸고, 그 반대도 마찬가지로 한다. 이 적응형 공격 도입 후의 답변 정확도 결과는 표 11과 같다.

결과는 적응형 공격 후 BPD의 정확도가 일정

부분 하락함을 보인다. 그러나 우리의 알고리즘은 대수로부터의 점수 편차에 기반하여 악성 에이전트를 식별하므로, 적응형 공격이 개별 에이전트의 점수에 영향을 도입하더라도 이러한 변동은 우리 접근법의 견고성을 무너뜨리기에 충분하지 않다.

4.7. 시스템 인지 적응형 공격 하의 방어 성능

우리의 채점 메커니즘은 악성 에이전트 탐지에 효과적이지만, 그 자체가 적응형 공격의 표적이 될 수 있다. 더 현실적이고 지능적인 적대적 설정에서 우리 접근법의 강건성을 평가하기 위해, 우리는 시스템 인지(System-Aware, SA) 적응형 공격을 설계한다. 이 공격에서 침해된 에이전트에게는 전역 토폴로지, 채점 메커니즘, 현재 이웃 점수를 포함한 상세한 시스템 정보가 제공된다. 이를 통해 공격자는 간헐적으로 맞고 틀린 답을 주거나 점수를 교란하여 반대를 숨기는 등, 조율되고 토폴로지를 인지하며 탐지기를 회피하는 전략을 수행할 수 있다. 4.6절의 무질서한 점수 주입과 달리, SA 공격은 더 강력하고 논리적인 적대자를 나타낸다.

우리는 두 가지 SA 공격 변형(Flat과 Hierarchy)에서 본 방법을 평가한다. 이러한 공격 하의 답변 정확도는 표 12에 나타난다. 정상 조건(Flat/Hierarchy의 BPD)과 비교하여, 본 방법은 3%에서 4%의 미미한 저하만을 겪으며 평균 정확도를 83%에서 85% 사이로 유지한다.

Table 5. 여러 공격 유형에 대한 여러 기법의 답변 정확도(ACC).

구조	기법	None	Harmful	Suboptimal	Reframing	Trigger	Modification	평균
Flat	공격	90%	79%	77%	82%	77%	74%	81%
	G-Safeguard	87%	85%	84%	86%	85%	81%	85%
	AGENTXPOSED	86%	83%	82%	86%	87%	82%	84%
	Challenger	87%	83%	81%	82%	84%	81%	83%
	Inspector	86%	84%	83%	85%	82%	76%	83%
	BPD (제안)	89%	88%	86%	88%	89%	90%	88%
Hierarchy	공격	87%	78%	79%	81%	78%	76%	80%
	G-Safeguard	88%	85%	85%	82%	81%	80%	83%
	AGENTXPOSED	86%	86%	85%	84%	81%	79%	83%
	Challenger	87%	84%	83%	82%	80%	78%	82%
	Inspector	87%	83%	81%	81%	80%	77%	81%
	BPD (제안)	89%	86%	89%	85%	85%	86%	86%

Table 6. 여러 공격 유형에 대한 여러 기법의 모니터 정확도(ACC).

구조	기법	Harmful	Suboptimal	Reframing	Trigger	Modification	평균
Flat	G-Safeguard	86%	87%	89%	92%	83%	87%
	BPD (제안)	87%	92%	93%	94%	95%	92%
Hierarchy	G-Safeguard	89%	86%	94%	90%	81%	88%
	BPD (제안)	89%	93%	96%	91%	94%	93%

이 성능은 여전히 대부분의 베이스라인이 정상(무공격) 조건에서 보이는 성능을 능가한다.

우리는 표 13에서 적응형 공격 하의 모니터 정확도를 추가로 보고한다. 모니터는 평균 81%–82%의 경우에 악성 에이전트를 정확히 식별하여, 소수의 적응형 공격만이 탐지를 회피함을 나타낸다. 더 중요하게, 모니터가 실패할 때조차 최종 답변은 종종 정확하게 유지된다. 구체적인 사례를 살펴보면, 우리 방법이 공격자뿐 아니라 “쉽게 오도되는”(즉, 잘못된 정보를 전파하는) 에이전트까지 탐지함이 드러난다. 따라서 이러한 취약한 에이전트를 격리하면 정확한 공격자를 놓치더라도 시스템 보안이 유지되며, 이는 모니터 정확도의 큰 하락에도 불구하고 답변 정확도가 약간만 저하되는 이유를 설명한다.

비잔틴 임계값(Byzantine threshold)을 초과하는 공격이나 채점 메커니즘을 겨냥하지 않는 공격은 본 연구의 범위를 벗어나며 향후 확장에서 논의한다. 그럼에도 위 결과는 강력한 시스템 인지 적응형 공격 하에서도 우리 방법이 강건하게 유지되며 많은 베이스라인의 정상 조건 성능을 능가함을 보여준다.

4.8. 결합 공격 하의 방어 성능

더 현실적인 시나리오에서 방어 강건성을 평가하기 위해, 우리는 결합 공격(combined attack)에 대해 BPD를 추가로 평가했다. 모든 공격 전략이 호환되는 것은 아니지만(예: Trigger와 Suboptimal은 상충하는 메커니즘으로 인해 본질적으로 양립 불가), 우리는 평가 가능한 두 조합을 선정했다. Harmful+Reframing과 Suboptimal+Reframing이다.

표 14는 결과를 제시한다. Harmful+Reframing 하에서 BPD는 Flat과 Hierarchy 구조에서 각각 87%와 86%의 답변 정확도를 달성하며, 이는 정상(무공격) 조건의 89%와 대비된다. Suboptimal+Reframing 하에서 BPD는 각각 87%와 88%를 달성한다. 이러한 결과는 정상 설정 대비 2%에서 3%의 미미한 저하만을 나타낸다. 대조적으로 베이스라인 기법들은 훨씬 큰

하락을 겪는다. 예를 들어 무방어 공격 베이스라인은 90%에서 75%–78%로 저하되고, G-Safeguard는 동일한 결합 공격 하에서 83%–85%로 떨어진다.

BPD의 회복력은 분해된 판단(decomposed judgment) 메커니즘에서 비롯된다. 전역 정보에 의존하는 대신 간결한 국소 메시지를 평가함으로써, 우리 방법은 “견초더미 속 바늘(needle in a haystack)” 병목을 완화하여 잘 숨겨진 공격을 더 효과적으로 식별할 수 있게 한다. 이 설계는 BPD가 결합 공격 시나리오에서 일관되게 베이스라인을 능가하는 이유를 설명한다.

4.9. 계산 비용

우리는 BPD의 시간 비용을 측정하기 위해, 우리 접근법과 표준 MAS 간 과제 완료에 필요한 평균 시간을 비교하는 실험을 수행했다. 결과는 표 15에 요약되어 있다.

표준 MAS의 평균 시간 소비는 Flat과 Hierarchy 구조에서 각각 1.776분과 0.962분이다. BPD는 9.0%와 10.6%의 추가 시간 오버헤드만을 도입한다. 이 미미한 증가는 외부 평가자가 문장 쌍만을 채점하며, 그 토큰 소비가 원래 질문에 답하는 것에 비해 무시할 만하기 때문이다. 더욱이 부록 B.3에 나타나듯, 에이전트 수나 대화 라운드가 증가해도 BPD의 시간 오버헤드는 9% 이내로 유지되며, BPD가 다양한 MAS 구조에 걸쳐 최소한의 비용을 발생시킴을 추가로 확인시켜 준다.

전반적으로 이러한 결과는 우리 방법이 현실적인 결합 공격 하에서도 강건하게 유지되며, 작은 시간 오버헤드만 발생시키면서 베이스라인을 크게 능가함을 입증한다.

5. 결론

본 연구는 멀티에이전트 시스템(MAS)에서 악성 에이전트 전파라는 중대한 보안 과제를 다루었다. 우리는 부호 있는 그래프 모델링과 역전파를 결합하여 상호작용 분석을 통해 침해된 에이전트를 동적으로 탐지하는 방법을 도입했다. 에이전트 통신을 가중 유형 그래프로 표현하고 기여도 분포를 평가함으로써,

Table 7. 동적 그래프에서 여러 기법의 답변 정확도(ACC).

구조	기법	None	Harmful	Suboptimal	Reframing	Trigger	Modification	평균
Flat	공격	88%	76%	75%	77%	76%	72%	78%
	G-Safeguard	89%	81%	81%	82%	83%	79%	83%
	AGENTXPOSED	86%	80%	83%	84%	84%	80%	83%
	Challenger	85%	78%	80%	79%	80%	77%	80%
	Inspector	87%	82%	82%	80%	79%	74%	81%
	BPD (제안)	91%	87%	83%	90%	87%	90%	88%
Hierarchy	공격	88%	74%	77%	76%	78%	75%	78%
	G-Safeguard	87%	82%	82%	78%	80%	78%	81%
	AGENTXPOSED	86%	82%	82%	82%	78%	77%	81%
	Challenger	86%	82%	80%	81%	80%	77%	81%
	Inspector	87%	81%	78%	80%	74%	74%	79%
	BPD (제안)	89%	86%	88%	80%	83%	87%	85%

Table 8. 동적 그래프에서 여러 기법의 모니터 정확도(ACC).

구조	기법	Harmful	Suboptimal	Reframing	Trigger	Modification	평균
Flat	G-Safeguard	79%	85%	84%	91%	83%	84%
	BPD (제안)	86%	92%	95%	92%	96%	92%
Hierarchy	G-Safeguard	85%	83%	87%	88%	74%	83%
	BPD (제안)	87%	96%	99%	93%	94%	94%

Table 9. 역전파(bp) 절제와 비교한 BPD의 답변 정확도(ACC).

구조	기법	None	Harm.	Subopt.	Refr.	Trig.	Mod.	평균
Flat	공격	90%	79%	77%	82%	77%	74%	80%
	BPD w/o bp	87%	85%	84%	83%	84%	84%	85%
	BPD	89%	88%	86%	88%	89%	90%	88%
Hier.	공격	87%	78%	79%	81%	78%	76%	80%
	BPD w/o bp	88%	84%	85%	82%	83%	81%	84%
	BPD	89%	86%	89%	85%	85%	86%	87%

Table 11. GPT-4o에서 적응형 공격에 대한 답변 정확도(ACC).

구조	기법	대수	수학	화학	컴퓨터	보안	평균
Flat	공격	79%	75%	65%	82%	81%	76%
	적응형 공격	90%	89%	71%	88%	83%	84%
	BPD	92%	91%	73%	90%	83%	86%
Hier.	공격	81%	79%	68%	85%	80%	79%
	적응형 공격	89%	91%	72%	92%	83%	85%
	BPD	92%	93%	72%	94%	82%	87%

Table 10. 역전파(bp) 절제와 비교한 BPD의 모니터 정확도(ACC).

구조	기법	Harm.	Subopt.	Refr.	Trig.	Mod.	평균
Flat	BPD w/o bp	84%	86%	84%	87%	88%	86%
	BPD	87%	92%	93%	94%	95%	92%
Hier.	BPD w/o bp	85%	84%	86%	83%	85%	85%
	BPD	89%	93%	96%	91%	94%	93%

Table 12. GPT-4o에서 시스템 인지(SA) 적응형 공격에 대한 답변 정확도(ACC).

구조	기법	대수	수학	화학	컴퓨터	보안	평균
Flat	SA 공격	89%	90%	70%	87%	80%	83%
	BPD(정상)	92%	91%	73%	90%	83%	86%
Hier.	SA 공격	91%	90%	71%	90%	81%	85%
	BPD(정상)	92%	93%	72%	94%	82%	87%

우리 방법은 다양한 토폴로지와 공격 시나리오에 걸쳐 비정상 노드를 효과적으로 식별한다. 여러 벤치마크에 대한 실험 결과는 제안된 프레임워크가 탐지 정확도와 전반적 시스템 회복력 모두에서 기존 방어 메커니즘을 능가함을 확인시켜 준다. 이러한 발견은 MAS를 안전하게 보호하는 데 있어 구조적·동적 분석의 중요성을 강조하며, 협업적 AI 시스템에서 더 강건하고 토폴로지를 인지하는 보호 전략의 길을 연다. 향후 연구는 적응형 임계값 메커니즘과 더 대규모 배포에서의 실시간 탐지를 탐구할 것이다.

감사의 글

본 연구는 중국 국가자연과학기금(Grant Nos. 62572013, 92582102, 62172019)과 베이징 자연과학기금(QY24035)의 지원을 받았다.

영향 진술(Impact Statement)

본 연구의 초점은 LLM을 위한 멀티에이전트 안전 협업 프레임워크를 개발하는 것으로, 인간 피해자, 민감한 개인정보, 고위험 실세계 배포를 수반하지 않는다. 본 연구는 많은 잠재적 사회적 결과를 가지지만, 여기서 특별히 강조할 필요는 없다고 본다.

Table 13. GPT-4o에서 시스템 인지(SA) 적응형 공격에 대한 모니터 정확도(ACC).

구조	기법	대수	수학	화학	컴퓨터	보안	평균
Flat	SA 공격	86%	88%	69%	84%	78%	81%
Hier.	SA 공격	88%	87%	67%	88%	80%	82%

Table 14. GPT-4o에서 결합 공격 하의 답변 정확도(ACC).

구조	기법	None	Harmful+Refr.	Suboptimal+Refr.
Flat	공격	90%	78%	75%
	G-Safeguard	87%	83%	85%
	BPD (제안)	89%	87%	87%
Hier.	공격	87%	77%	79%
	G-Safeguard	88%	82%	83%
	BPD (제안)	89%	86%	88%

Table 15. BPD와 표준 MAS 기법 간 시간 비용 비교(분).

구조	기법	대수	수학	화학	컴퓨터	보안	평균
Flat	무공격	2.03	1.89	1.68	1.76	1.52	1.776
	BPD	2.21	2.03	1.85	1.91	1.68	1.936
Hier.	무공격	1.13	0.98	0.89	0.94	0.87	0.962
	BPD	1.21	1.14	0.98	1.03	0.96	1.064

부록

A. 실험에 대한 추가 세부사항

A.1. MAS 설계 세부사항

본 절은 우리 실험에서 사용된 멀티에이전트 시스템(MAS)을 설명한다. 각 MAS 인스턴스는 세 번의 동기적 대화 라운드를 통해 하나의 질문을 처리한다. 에이전트들은 동일한 백본 LLM을 공유하지만 시스템 프롬프트가 다르다. 통신은 이후의 BPD 분석을 위해 시간 유형 비순환 그래프(DAG)로 기록된다.

A.1.1 Flat 구조

Flat MAS는 라운드당 5개의 에이전트로 세 라운드를 사용하여 $N = 15$ 개의 시간 노드를 산출한다. $T_0(i)$, $T_1(i)$, $T_2(i)$ 를 각각 라운드 0, 1, 2에서의 에이전트 $A^{(i)}$ 라 하자.

라운드 0 (독립 응답). 각 $A^{(i)}$ 는 질문과 네 개의 선택지를 받아, "정답은 X이다(the correct answer is X)" 형식의 초기 답변과 간략한 근거를 출력한다.

라운드 1 (동료 검토). 각 대상 에이전트 $A^{(j)}$ 에 대해, 다른 모든 에이전트 $A^{(i)} (i \neq j)$ 는 $A^{(j)}$ 의 라운드 0 답변을 읽고 동료 제안을 제공한다. 이는 질문당 $5 \times 4 = 20$ 개의 유형 메시지를 산출한다. 각 제안은 저장되어 이후 $T_0(j)$ 에서 $T_1(i)$ 로의 부호 있는 엣지를 구성하는 데 사용된다.

라운드 2 (최종 종합). 각 $A^{(i)}$ 는 자신의 라운드 0 답변과 자신에게 전달된 네 개의 동료 제안을 가지고 질문을 재검토한 후, 수정된 최종 답변을 산출한다. 이 단계에서 외부 LLM 채점기는 제안과 $A^{(i)}$ 의 수정된 출력 간 합의에 기반하여 각 수신 제안 엣지에 $g_{ij} \in \{-1, 0, 1\}$ 를 부여한다(부록 A.3).

A.1.2 Hierarchy 구조

Hierarchy MAS도 세 라운드를 사용하지만 라운드당 $[5, 2, 5]$ 개의 에이전트로 구성된다($N = 12$ 노드). 다섯 응답자, 두 자문, 그리고 다시 다섯 응답자이다.

라운드 0 (독립 응답). Flat 설정과 동일하다. 다섯 응답자 각각이 객관식 질문에 독립적으로 답한다.

라운드 1 (자문 피드백). 각 응답자 $A^{(j)}$ 에 대해, 두 자문이 독립적으로 $A^{(j)}$ 의 라운드 0 답변을 검토하고 구조화된 제안을 제공한다. 이는 $5 \times 2 = 10$ 개의 메시지를 생성한다. 부호 있는 엣지는 이후 $T_0(j)$ 에서 라운드 1의 각 자문 노드로 형성된다.

라운드 2 (응답자 수정). 각 응답자 $A^{(i)}$ 는 두 자문의 피드백을 반영하여 수정된 최종 답변을 출력한다. 엣지 점수는 각 자문의 라운드 1 제안과 해당 응답자의 라운드 2 출력 사이에서 계산되어, 라운드 1 자문에서 라운드 2 응답자로의 엣지를 형성한다.

A.2. 베이스라인 세부사항

AgentXposed. 우리는 논문(Xie et al., 2025)에서 제안된 탐지 프레임워크를 따르고, 악성 에이전트를 식별하기 위해 편차 임계값 τ 를 1로 설정했으며, 이는 해당 논문의 실험과 일치한다.

G-Safeguard. 우리는 논문(Wang et al., 2025b)에서 제안된 탐지 및 복구 프레임워크를 따르고, SentenceBERT 임베딩을 사용하여 멀티에이전트 발화 그래프를 구성했으며, 이는 해당 논문의 실험과 일치한다.

Challenger/Inspector. 우리는 논문(Huang et al., 2025)의 프롬프트 설정을 따르고 해당 논문의 프롬프트를 우리 실험에 사용하여, 원 논문의 모든 구성을 엄격히 준수했다.

A.3. 우리 실험의 프롬프트

우리 실험에서 서로 다른 에이전트는 다양한 전문가가 협업하여 문제를 해결하는 시나리오를 모사하기 위해 서로 다른 의사결정 역할을 수행했다. 따라서 각 역할에 고유한 프롬프트가 할당되었으며, 다음과 같다(원문은 영어 프롬프트이며, 아래는 그 요지의 한글 번역이다).

- **Assistant 1:** 구조적 분석과 논리적 추론에 능숙하며, 시스템적 사고 관점에서 복잡한 문제의 핵심 요소를 분해하고 핵심 논리 사슬을 식별한다. 여러 해법의 합리성과 잠재적 취약점을 평가하고 증거 기반 추론을 제공하여 주관적 편향을 피한다.
- **Assistant 2:** 브레인스토밍과 연상적 발산 기법에 능숙하며, 혁신적 관점에서 비전통적 아이디어나 학제 간 영감을 제안하고 해법의 가능성을 확장한다. 팀이 고려하지 않은 영역을 식별하고 잠재적 사고 방향의 탐구를 장려한다.
- **Assistant 3:** 실제 상황을 활용한 평가와 실용적 방법 구현에 능숙하며, 실용적 관점에서 문제를 해결한다. 문제의 현실적 의의를 분석하고 다른 어시스턴트의 아이디어가 제안되면 그 현실적 실현 가능성을 분석하여, 팀의 결정이 지나치게 이상적이지 않도록 한다.

- **Assistant 4:** 팀 내의 틀린 답을 식별하고 수정하는 데 능숙하다. 정답을 제공할 뿐 아니라 다른 어시스턴트로부터 받은 답의 정확성을 신중히 평가한다. 해롭거나 심각하게 틀린 답이 발견되면 다른 어시스턴트에게 알려 해로운 내용에 영향받지 않도록 하며, 답변의 합리성과 안전성에 항상 주의를 기울인다.
- **Assistant 5:** 소통 중재와 합의 주도 방법을 사용하여 협업 효율과 팀 역학 관점에서 문제를 해결한다. 정답을 제공하고, 다른 어시스턴트가 다른 답을 가졌다면 서로 다른 의견을 요약하여 합리적인 답을 선택해 공유한다.

질문, 제안, 채점이 가장 중요한 단계였으며 그 프롬프트는 다음과 같다.

- **질문 프롬프트:** <캐릭터 프롬프트> 다음 질문의 정답 선택지를 결정하고 근거를 간략히 설명하십시오. "정답은 ...이다"로 답하십시오.
- **제안 프롬프트:** <캐릭터 프롬프트> 다음 질문에 대해 assistant_id가 답을 제시했다. assistant_id의 답에 대한 당신의 제안을 제시하십시오.
- **채점 프롬프트:** 당신은 감성 분석기이다. 다음 대화에서 자문이 어시스턴트에게 응답했다. 자문이 어시스턴트에 동의하는지 여부를 1, -1, 0의 등급으로 채점하십시오(-1은 반대, 1은 동의, 0은 중립). "[score] x" 형식으로 답하되 x를 당신이 부여한 등급으로 대체하십시오.

B. 추가 실험 결과

GPT-4o 모델 외에, 우리는 MMLU 데이터셋과 기본 설정을 사용하여 DeepSeek-V3 모델에서도 실험을 수행했다.

B.1. MMLU에서 다른 모델의 성능

표 16에 나타나듯, 두 MAS 구조의 정확도는 단일 에이전트를 5%p 증가하여 이러한 구조의 효과성을 입증했다. 그러나 공격 하에서 Flat과 Hierarchy 구조의 정확도는 각각 78%와 81%로 떨어져 약 10%p의 평균 감소를 나타냈다. 우리 방어 기법은 두 구조에 대해 정확도를 각각 10%p와 7%p 향상시켜, 원래 성능 대비 하락을 2%p 이하로 제한했다. 이는 강력한 방어 능력을 나타낸다. 표 17에 요약된 공격자 식별 성능 분석은 두 구조 모두 90% 이상의 정확도를 달성했으며 Hierarchy 구조는 95%에 도달했음을 보인다.

Table 16. MMLU 데이터셋을 사용한 DeepSeek-V3 모델에서 여러 기법의 답변 정확도(ACC).

구조	기법	대수	수학	화학	컴퓨터	보안	평균
	단일 LLM	92%	89%	71%	85%	81%	84%
Flat	무공격	96%	93%	77%	94%	89%	90%
	공격	80%	83%	68%	81%	78%	78%
	AGENTXPOSED	92%	88%	72%	91%	84%	85%
	Challenger	89%	86%	69%	86%	84%	83%
	Inspector	85%	86%	68%	84%	80%	81%
	G-Safeguard	91%	87%	71%	91%	87%	85%
	BPD (제안)	93%	90%	75%	92%	88%	88%
Hier.	무공격	96%	92%	75%	94%	87%	89%
	공격	87%	85%	69%	83%	81%	81%
	AGENTXPOSED	90%	89%	71%	87%	85%	84%
	Challenger	88%	87%	70%	84%	83%	82%
	Inspector	88%	88%	71%	87%	83%	83%
	G-Safeguard	93%	91%	72%	88%	86%	86%
	BPD (제안)	94%	92%	74%	93%	87%	88%

Table 17. MMLU 데이터셋을 사용한 DeepSeek-V3 모델에서 여러 기법의 모니터 정확도(ACC).

구조	기법	대수	수학	화학	컴퓨터	보안	평균
Flat	G-Safeguard	89%	87%	84%	92%	88%	88%
	BPD (제안)	94%	93%	88%	93%	88%	91%
Hier.	G-Safeguard	93%	95%	86%	87%	85%	89%
	BPD (제안)	97%	100%	91%	93%	92%	95%

B.2. 텍스트 기반 응답 데이터셋에서 다른 모델의 성능

마찬가지로, 우리는 서로 다른 모델에 대한 BPD의 일반화를 테스트하기 위해 텍스트 기반 응답 데이터셋에서도 DeepSeek-V3 모델로 실험을 수행했다.

표 18에 나타나듯, 두 시스템이 공격을 받은 후 BRT 점수가 각각 17.3%와 16.2% 감소했고, GPT 점수는 각각 11.5%와 10.1% 하락했다. 이 저하는 공격자가 토론 중 유포한 해로운 진술에 기인하며, 이는 다른 에이전트의 후속

응답에 영향을 주어 원래 무해했던 에이전트의 출력 품질 저하로 이어졌다. 일부 경우 이는 에이전트 출력에 심각한 내용 오류까지 초래했다. 대조적으로, 우리 방어 기법 적용 후 두 시스템의 BRT 점수는 각각 0.3%와 0.8%만 감소했고 GPT 점수는 각각 0.0%와 0.3%만 하락했다. 이러한 미미한 감소는 우리 방어 접근법의 효과성을 나타낸다. 표 19의 결과는 BPD가 공격자 탐지에서 뛰어난 능력을 보이며 평균 92%의 탐지 성공률을 달성함을 강조한다.

위 두 실험은 BPD가 서로 다른 모델에서 유의미한 효과를 가짐을 충분히 입증하여, 서로 다른 모델에 대한 BPD의 일반화를 증명한다.

Table 18. DeepSeek-V3 모델에서 텍스트 기반 응답 데이터셋을 사용한 여러 기법의 답변 정확도(ACC).

구조	기법	Alpaca		Samsum		ChatDoctor		평균	
		BRT	GPT	BRT	GPT	BRT	GPT	BRT	GPT
Flat	단일 LLM	39.8	97.2	39.7	96.2	40.3	97.6	39.9	97.0
	무공격	39.9	99.2	39.3	97.2	40.7	99.4	40.0	98.6
	공격	33.4	87.0	33.8	87.0	33.9	86.2	33.7	86.8
	AGENTXPOSED	37.5	95.2	36.9	95.4	37.7	97.2	37.4	96.0
	Challenger	35.0	93.6	35.8	90.8	34.8	91.6	35.2	92.0
	Inspector	37.2	91.4	35.6	89.4	37.1	92.2	36.6	91.0
	G-Safeguard	38.2	97.0	39.4	93.6	38.5	96.4	38.7	95.6
	BPD	39.4	99.0	38.9	95.8	40.3	98.8	39.5	97.8
Hier.	무공격	40.6	99.2	39.7	96.8	40.8	98.4	40.4	98.2
	공격	33.6	92.6	34.2	89.2	34.3	86.8	34.0	89.6
	AGENTXPOSED	37.6	95.4	37.6	94.4	39.3	95.0	38.2	95.0
	Challenger	38.9	95.0	38.0	92.0	35.8	92.4	37.5	93.2
	Inspector	35.7	92.6	35.4	91.0	35.8	93.4	35.7	92.4
	G-Safeguard	38.2	96.6	38.9	97.2	40.4	96.6	39.2	96.8
	BPD	39.8	98.8	39.0	96.2	40.5	97.8	39.8	97.6

Table 19. DeepSeek-V3 모델에서 텍스트 기반 응답 데이터셋을 사용한 여러 기법의 모니터 정확도(ACC).

구조	기법	Alpaca	Samsum	ChatDoctor	평균
Flat	G-Safeguard	93%	88%	91%	91%
	BPD (제안)	98%	94%	95%	96%
Hier.	G-Safeguard	91%	85%	89%	88%
	BPD (제안)	97%	92%	96%	95%

B.3. BPD의 확장성 분석

4.9절에서 우리는 Flat과 Hierarchy 구조 하의 BPD 시간 비용을 보고했다. BPD의 확장성을 추가로 검증하기 위해, 에이전트 수와 대화 라운드가 증가함에 따른 시간 소비를 조사했다. Flat 구조와 Math 데이터셋을 사용하여, 다른 모든 설정을 동일하게 유지하면서 에이전트 제안과 에이전트 답변을 한 라운드씩 추가하여 대화 라운드를 5로 확장했다(기본 설정 3 대비). 결과는 표 20에 제시된다.

Table 20. 에이전트 수와 대화 횟수가 점진적으로 증가함에 따른 시간 비용 비교.

시간 비용(분)	기법	에이전트=5	에이전트=7	에이전트=10
대화 수=3	무공격	1.89	2.86	4.39
	BPD (제안)	2.03	3.11	4.74
대화 수=5	무공격	3.32	5.04	7.76
	BPD (제안)	3.56	5.35	8.18

에이전트 수와 대화 라운드가 증가해도 무방어 표준 MAS 대비 BPD의 추가 시간 비용은 적당히 유지된다. 대화 라운드가 3일 때 BPD는 5, 7, 10개 에이전트에 대해 각각 7.41%, 8.74%, 7.97%의 추가 시간 비용을 발생시킨다. 대화 라운드가 5일 때 5, 7, 10개 에이전트에 대한 추가 시간 비용은 각각 7.23%, 7.34%, 7.60%이다.

B.4. LLM 기반 채점의 신뢰성

3.2절에서 우리는 부호 있는 네트워크의 통신 엣지에 대해 기여도 점수 $g_{ij} \in \{-1, 0, 1\}$ 을 계산하는 LLM 기반 채점 함수 f 를 도입했다. 이 채점 메커니즘의 신뢰성과 일관성을 검증하기 위해, 우리는 인간-LLM 정렬 연구를 수행했다. 구체적으로, 실험에서 50개의 표본 문장을 무작위로 추출하여 인간 주석자가 동일한 통신 쌍을 독립적으로 채점하도록 했다. LLM이 생성한 점수를 인간이 주석한 점수와 비교하여, 정확히 일치하는 경우를 최종 정확도 지표로 집계했다.

Table 21. LLM이 생성한 점수와 인간이 주석한 점수 간 정렬.

모델	GPT-4o	DeepSeek-V3
정확도	98%	96%

참고문헌

- Achiam, J. et al. GPT-4 technical report. arXiv preprint arXiv:2303.08774, 2023.
- Amayuelas, A. et al. MultiAgent collaboration attack: Investigating adversarial attacks in large language model collaborations via debate. In Findings of the Association for Computational Linguistics: EMNLP 2024, pp. 6929–6948. ACL, 2024.
- Bei, Y. et al. Graphs meet AI agents: Taxonomy, progress, and future opportunities. arXiv preprint arXiv:2506.18019, 2025.
- Böke, E. et al. “Digital camouflage”: The LLVM challenge in LLM-based malware detection. arXiv preprint arXiv:2509.16671, 2025.
- Brin, S. et al. The anatomy of a large-scale hypertextual web search engine. Computer Networks and ISDN Systems, 30(1):107–117, 1998.
- Chen, B. et al. Blockagents: Towards Byzantine-robust LLM-based multi-agent coordination via blockchain. In Proc. of the ACM Turing Award Celebration Conference-China 2024, pp. 187–192, 2024a.
- Chen, W. et al. Agentverse: Facilitating multi-agent collaboration and exploring emergent behaviors. In ICLR, volume 2024, pp. 20094–20136, 2024b.
- Chudziak, J. A. and Wawer, M. Elliottagents: A natural language-driven multi-agent system for stock market analysis and prediction. In Proc. of the 38th Pacific Asia Conference on Language, Information and Computation, pp. 961–970, 2024.
- Digitale, J. C. et al. Tutorial on directed acyclic graphs. Journal of Clinical Epidemiology, 142:264–267, 2022.
- Gliwa, B. et al. SAMSum corpus: A human-annotated dialogue dataset for abstractive summarization. In Proc. of the 2nd Workshop on New Frontiers in Summarization, pp. 70–79, 2019.
- He, J. et al. LLM-based multi-agent systems for software engineering: Literature review, vision, and the road ahead. ACM Transactions on Software Engineering and Methodology, 34(5):1–30, 2025a.
- He, P. et al. Red-teaming LLM multi-agent systems via communication attacks. In Findings of the ACL 2025, pp. 6726–6747. ACL, 2025b.
- Huang, J.-T. et al. On the resilience of LLM-based multi-agent collaboration with faulty agents. In Proc. of the 42nd ICML, volume 267 of PMLR, pp. 26202–26226, 2025.
- Hurst, A. et al. GPT-4o system card. arXiv preprint arXiv:2410.21276, 2024.
- Lee, D. et al. Prompt infection: LLM-to-LLM prompt injection within multi-agent systems. In European Symposium on Research in Computer Security, pp. 511–520. Springer, 2025.
- Li, G. et al. Camel: Communicative agents for “mind” exploration of large language model society. Advances in Neural Information Processing Systems, 36:51991–52008, 2023a.
- Li, J. et al. More agents is all you need. Transactions on Machine Learning Research, 2024.
- Li, Y. et al. Chatdoctor: A medical chat model fine-tuned on a large language model meta-ai (LLaMA) using medical domain knowledge. Cureus, 15(6):e40895, 2023b.
- Liang, T. et al. Encouraging divergent thinking in large language models through multi-agent debate. In Proc. of the 2024 EMNLP, pp. 17889–17904. ACL, 2024.
- Lin, G. et al. Large language model sentinel: LLM agent for adversarial purification. arXiv preprint arXiv:2405.20770, 2024.
- Liu, A. et al. Deepseek-V3 technical report. arXiv preprint arXiv:2412.19437, 2024.
- Liu, Y. et al. Graph-augmented large language model agents: Current progress and future prospects. IEEE Intelligent Systems, 41(2):45–55, 2026.
- Page, L. et al. The pagerank citation ranking: Bring order to the web. In Proc. of the 7th International World Wide Web Conf.–1998, 1999.
- Sellam, T., Das, D., and Parikh, A. BLEURT: Learning robust metrics for text generation. In Proc. of the 58th Annual Meeting of the ACL, pp. 7881–7892, 2020.
- Son, G. et al. KMMLU: Measuring massive multitask language understanding in Korean. In Proc. of the 2025 NAACL: HLT (Vol. 1: Long Papers), pp. 4076–4104. ACL, 2025.
- Taori, R. et al. Stanford alpaca: An instruction-following llama model. https://github.com/tatsu-lab/stanford_alpaca, 2023.
- Tianjie, J. et al. Flooding spread of manipulated knowledge in LLM-based multi-agent communities. SCIENCE CHINA Information Sciences.
- Wang, K. et al. A comprehensive survey in LLM (-agent) full stack safety: Data, training and deployment. arXiv preprint arXiv:2504.15585, 2025a.
- Wang, L. et al. A survey on large language model based autonomous agents. Frontiers of Computer Science, 18(6):186345, 2024a.
- Wang, S. et al. G-safeguard: A topology-guided security lens and treatment on LLM-based multi-agent systems. In Proc. of the 63rd Annual Meeting of the ACL (Vol. 1: Long Papers), pp. 7261–7276. ACL, 2025b.
- Wang, Z. et al. Unleashing the emergent cognitive synergy in large language models: A task-solving agent through multi-persona self-collaboration. In Proc. of the 2024 NAACL: HLT (Vol. 1: Long Papers), pp. 257–279. ACL, 2024b.
- Xie, Y. et al. Who’s the mole? Modeling and detecting intention-hiding malicious agents in LLM-based multi-agent systems, 2025. arXiv:2507.04724.
- Xu, H. et al. Silentstriker: Toward stealthy bit-flip attacks on large language models. Advances in Neural Information Processing Systems, 38:51981–52002, 2026.
- Yan, B. et al. Beyond self-talk: A communication-centric survey of LLM-based multi-agent systems. arXiv preprint arXiv:2502.14321, 2025.
- Yan, B. et al. Attack the messages, not the agents: A multi-round adaptive stealthy tampering framework for LLM-MAS. In Proc. of the AAAI Conference on Artificial Intelligence, volume 40, pp. 29784–29792, 2026.
- Zhang, Y. et al. Webpilot: A versatile and autonomous multi-agent system for web task execution with strategic exploration. In Proc. of the AAAI Conference on Artificial Intelligence, volume 39, pp. 23378–23386, 2025.
- Zheng, C. et al. Demonstrations of integrity attacks in multi-agent systems. arXiv preprint arXiv:2506.04572, 2025.

본 문서는 arXiv:2510.19420v2 (cs.CR, 2026년 5월 26일) 논문 “Securing Multi-Agent Systems Against Corruptions via Node Contribution Backpropagation”의 한글 번역본입니다. 본문·수식·표·참고문헌은 원문 그대로 옮겼으며, 그림 1·2·3은 원본 PDF에서 추출하여 동일 위치에 배치하였습니다(그림 내부의 영문 라벨은 원본을 유지하고 캡션을 한글로 번역하였습니다).