

AGENTDAG BIBLE · 종합 프레젠테이션

연구 지형도 & 실험 설계

DAG 기반 멀티에이전트 LLM 파이프라인의
오류 전파 제어 및 평가 메커니즘 연구

문서 1 dag_research_landscape.md 문서 2 study.md 작성일 2026-05-09

목차

PART 1 — 연구 지형도

- **핵심 키워드 5개** 연구 분야 전체 구조
- **2-1** DAG 오케스트레이션
- **2-2** LLM-as-Judge / 평가
- **2-3** 오류 전파
- **2-4** HITL
- **2-5** 관측성
- **연구 공백 지도** (Gap Map)
- **우리 프로젝트의 위치**

PART 2 — 실험 설계 (STUDY Q&A)

- **Q1** DAG란 무엇인가
- **Q2** 연구 분야 순위
- **Q4-5** DAG 기술 핵심 & 구조
- **Q6** DAG 평가 요소 전체
- **Q7** 실험 기획 (Exp01-09)
- **Q8** 실험 결과 요약
- **Q9** 잔혹한 평가 — 개선점
- **Q10** Vanilla vs Others 비교


Part 1

연구 지형도

DAG 기반 멀티에이전트 LLM 연구의
5개 핵심 분야와 현재 공백

핵심 연구 키워드 5개

각 키워드는 독립된 연구 분야이면서 DAG 에이전트를 중심으로 교차한다.



2-1

DAG 오케스트레이션

논문	연도	핵심 내용
DynTaskMAS arXiv:2503.07675	ICAPS 2025	DAG 자동 생성 및 비동기 병렬 실행 스케줄링 — 실행 시간 21~33% 단축
Scheduler-Theoretic Framework arXiv:2604.11378	2026	LLM 그래프 형식적 태스크 스케줄링 이론화 (포지션 페이퍼, 실증 없음)
Why Do MAS Fail? MAST arXiv:2503.13657	2025	14개 실패 유형 분류, 7개 프레임워크 1,600+ 트레이스 분석

현재 한계

- 태스크 의존성(엣지)을 **사전에 수동 정의** — 실행 중 구조 변화 불가
- 그래프 토폴로지 자체의 적절성 검증 방법 없음
- 노드 단위 평가는 있으나 **파이프라인 전체 품질 기준** 없음

우리 연구 연결점

노드 게이트(평가 메커니즘)가
파이프라인 수준 품질에 미치는 영향 측정

LLM-as-Judge / 에이전트 평가

논문	연도	핵심 내용
LLM-as-a-Judge Survey arXiv:2411.15594	2024	G-Eval, Multi-LLM Judge, 편향 분류 종합 서베이
Crowd Comparative Reasoning arXiv:2502.12501	ACL 2025	Crowd 비교 추론 기반 평가 — 5개 벤치마크 평균 +6.7% 정확도
G-Eval EMNLP 2023/24 확장	2023–24	CoT 루브릭 + logprobs 가중 평균 → 인간 평가 정렬 개선

현재 한계

- **동일 모델 편향**: GPT는 GPT 출력에 더 높은 점수 (Exp06 직접 확인)
- 프롬프트 형식 변경만으로 점수 급변 — 재현성 낮음
- **완전성(Completeness) 미측정**: "요구한 걸 다 했는가" 검증 없음

우리 연구 연결점

평가 메커니즘의 S·C 문제 +
Completeness score 부재가 이 한계와 직결

2-3

오류 전파 (Error Propagation)

논문	연도	핵심 내용
Why Do MAS Fail? arXiv:2503.13657	2025	태스크 검증 실패가 최다 실패 유형 — 중간 검증 부재 가 핵심 원인
Sherlock arXiv:2511.00330	2024	오류 전파 차단 메커니즘 제안
Faulty Agents Resilience arXiv:2408.00989	ICML 2025	계층 구조 성능 하락 5.5% 로 최고 복원력 · 오류 96.4% 복구

현재 한계

- 현재 시스템은 **최종 출력만 검증** — 중간 노드 조기 차단 불가
- 오류 전파 범위의 **형식적 보장 없음**

우리 연구 핵심 주장

DAG 중간 노드 평가 게이트 →
오류 증폭 수치 감소 **실증**

17.2×

4.4×

?

독립 구조 증폭 중앙 감독 구조 게이트 DAG 목표

2-4

HITL

논문/사례	핵심
HULA arXiv:2411.12924 ICSE 2025	플랜 승인을 82%
GitHub Copilot Workspace 2025	멀티파일 변경 필수 승인 게이트

한계

- 언제 개입할지 기준 없음 — 임의 임계값
- 판단 부하(cognitive load) 높음
- 개입 후 재실행 범위 결정이 ad-hoc

AMBIGUOUS 판정 + `calculate_impact_factor()` 가
이 문제를 구조적으로 해결

2-5

관측성 & 트레이싱

도구	특징
OpenTelemetry LLM Tracing	벤더 종립 표준 (2024)
LangSmith / Langfuse	워크플로우 waterfall 트레이싱

한계

- 수천 번 실행의 집합적 패턴 탐지 불가
- 시맨틱 이상 표현 표준 없음

노드별 점수 시각화 →
병목 노드 즉시 파악 가능 (논문 Figure)

연구 공백 지도 (Gap Map)

현재 연구가 집중된 영역 → 우리가 파고들 수 있는 공백

DAG 실행 스케줄링	→	중간 노드 검증이 오류 전파에 미치는 효과
LLM 품질 평가 (G-Eval 등)	→	완전성(Completeness) 측정
단일 실행 트레이싱	→	파이프라인 전체 신뢰도 지표
HITL 개입 메커니즘	→	언제 개입할지 판단 기준

우리 프로젝트의 핵심 질문

기존 연구: "어떻게 DAG를 실행하는가" + "LLM 출력을 어떻게 평가하는가"

우리 추가: "**DAG** 중간 노드에 평가 게이트를 달면 오류 전파가 얼마나 줄어드는가"

Part 2

실험 설계

Study Q&A — DAG 기초부터 실험 결과까지

DAG 기초 & 기술 표준 (Q1 · Q4)

DAG란?

Directed Acyclic Graph. 방향 비순환 그래프.
노드 = AI 작업 단위 | 엣지 = 데이터 의존성
단순 체인과 달리 병렬 분기 + 복합 의존성 표현 가능

```
graph LR
    A --> B
    A --> C
    B --> D
    C --> D
```

(B, C 동시 실행)
(Fan-in)

7대 기술 표준

위상 정렬	Kahn's / DFS — 실행 순서 결정
Critical Path	최장 경로 = 전체 실행 하한
Dataflow 모델	데이터 가용성이 실행 트리거
역등성	동일 입력 → 동일 출력 (재시도 안전)
체크포인팅	노드 완료 시 상태 영속 저장
Fan-out / Fan-in	분배 → 합산 패턴
비순환 보장	정의 시점 DFS로 사이클 차단

DAG 평가 요소 전체 (Q6)

요소	기호	의미	측정 방법
유사도	S	동일 태스크 2회 응답 간 일치도	코사인 유사도 (embedding)
확신도	C	모델 자기 평가 정확도	자기보고 JSON / Logprobs YES·NO
편차	D	Critic이 감지한 오류 심각도	GPT Critic / QAG 퀴즈 / G-Eval CoT
모호성 지수	A-Score	종합 불확실성 (임의 설계)	$\alpha(1-S) + \beta \times D \times (1-C)$
일치도	W	3응답 간 그룹 합의	Kendall's W 프록시
우려 키워드	Z	모델 자체 불확실성 표현 수	텍스트 키워드 카운팅
조정 신뢰도	C_adj	Z로 감쇠된 C	$C \times 1/(1+\ln(1+Z))$
의존도 민감도	DSS	입력 변화 대비 출력 변화	섭동 후 코사인 거리
영향도 지수	I-Factor	수정 전파 범위	$\Sigma(R/(d+1))$
완전성	Completeness	요구 조건 충족 비율	QAG 또는 체크리스트 — 미구현

실험 기획 Exp01 – 09 (Q7)

실험	핵심 변경	가설	주요 발견
Exp01	Baseline (자율주행)	기준선 수립	$S \approx 1.0$ 포화 확인
Exp02	Baseline (SaaS)	도메인 고정 비교	전 노드 PASS, Critic 과관대
Exp03	$C \rightarrow \text{Logprobs YES/NO}$	자기보고 편향 노출	$A_{\text{Pricing}} C \approx 0.000$ (자기보고 ~ 0.9)
Exp04	$D \rightarrow \text{QAG 퀴즈 3문항}$	객관적 조건 충족 검증	$C_{\text{AdCopy}} 2/3$ 조건 누락 탐지 ($D=0.667$)
Exp05	$D \rightarrow \text{G-Eval CoT+logprobs}$	루브릭 기반 안정적 D	최저 노이즈, 가장 안정
Exp06	$D \rightarrow \text{Multi-LLM 평균}$	동일 모델 편향 제거	GPT $D=0.5$ vs Claude/Gemini $D=0.0$
Exp07	+ DSS 진단	고위험 upstream 식별	$A_{\text{Pricing}} \text{ DSS}=0.349$ 플래그
Exp08	$W + C_{\text{adj}} + Z$ (7-노드)	변별력 향상	범위 0.028~0.156 ($4\times$ 확장)
Exp09	Vanilla vs DAG	DAG 부가가치 실증	설계 완료 — 논문 핵심

실험 결과 요약 (Q8)

유효한 발견

- **Exp03**: Logprobs C — A_Pricing 실제 $C \approx 0.000$ (자기보고 ~ 0.9 편향 노출)
- **Exp04**: QAG — C_AdCopy 2/3 조건 누락 탐지 ($D=0.667$)
- **Exp05**: G-Eval — 가장 안정적, 최저 노이즈
- **Exp06**: Multi-LLM — GPT vs Claude/Gemini 편차로 동일 모델 편향 실증
- **Exp07**: DSS — A_Pricing $DSS=0.349$, 점수만으로 탐지 불가
- **Exp08**: F_BoardReport(0.156), G_RiskAudit(0.113) 최고 위험 노드 정확 식별

탐지 실패 — 침묵 실패

Exp08 D_ConditionAudit

5번째 조건 의도적 누락

→ $A=0.028$, $Z=0$, 판정 **PASS**

→ **Silent Failure**

A-SCORE 범위 비교

0.012–0.047 **0.028–0.156**

Exp02 Baseline

Exp08 개선 ($4\times$)

잔혹한 평가 — 개선점 (Q9)

① 침묵 실패

출력이 그럴듯하면 통과.

Completeness 검증 없음 → 누락 비탐지

→ QAG 체크리스트 필수

② Vanilla 기준선 없음

Exp01~08 전부 내부 비교.

"DAG가 없는 것보다 얼마나 낫나" 미측정

→ Exp09가 논문 성립의 전제

③ C 자기보고 편향

JSON 자기보고 C는 항상 0.8~1.0

→ Logprobs(Exp03) 또는 C_adj(Exp08)

④ Z 카운팅 조작

"note that", "assumption" 맥락 무관 동일 처리

→ 맥락별 가중치 / sentiment 분류

⑤ 단일 도메인

모든 실험: B2B SaaS Pricing

타 도메인 일반화 미검증

→ Exp10 신재용 데이터셋 확장

⑥ 임계값 고정

도메인·노드 역할 무관 동일 임계값

금융·의료는 더 엄격해야 함

→ U 활성화 / 도메인별 설정

Vanilla vs Others — 측정 가능한 것들 (Q10)

측정 항목	Vanilla 예측	DAG 예측	측정 방법
오류 전파율	높음	낮음	상위 노드 오류 → 하위 출력 변화율
조건 완전성	낮음	중간~높음	QAG 체크리스트
침묵 실패 빈도	높음	중간	의도적 결함 삽입 후 통과 여부
AMBIGUOUS 판정 수	0 (체계 없음)	측정됨	retry count
출력 일관성	낮음	높음	동일 태스크 N회 반복 분산
비용 대비 품질	낮은 비용, 낮은 품질	높은 비용, 높은 품질	API 호출 수 vs 개선폭

논문 핵심 Figure — 5-way 비교 구조

- VANILLA
- DAG-BASELINE (EXP02)
- DAG-BESTEVAL (EXP05)
- DAG-IMPROVED (EXP08)
- DAG-MULTIJUDGE (EXP06)

에이전트 연구 분야 순위 (Q2)

논문 기여 가능성(4) + 차별화 여지(3) + 현재 관심도(3) 기준

순위	분야	점수	DAG 포함
1	Multi-Agent Orchestration / DAG 구조	9.1	☑️ 핵심
2	LLM-as-Judge / Agent Evaluation	8.4	☑️ 연관
3	Planning & Reasoning (CoT, GoT, ToT)	8.0	⬆️ 부분
4	Error Recovery & Resilience	7.8	☑️ 연관
5	Human-in-the-Loop (HITL)	7.5	☑️ 연관
6	Agent Safety & Alignment	7.2	❌
7	Memory & Context Management	6.5	❌

DAG는 1위이면서 2·4·5위와 교차 — 단일 주제로 여러 분야를 포괄 가능

우리가 증명할 것

연구 질문

DAG 중간 노드에 평가 게이트를 달면 오류 전파가 얼마나 줄어드는가?

실험 설계

Vanilla vs Option1(게이트O, 백프롭X) vs Option2(게이트O, 백프롭O)

— 정형/비정형 태스크 분리 측정

측정 지표

오류 전파율 · 완전성(Completeness) · 침묵 실패 빈도